Terra-IA : faisabilité d'un scoring de constructibilité par LiDAR HD

Un MVP fonctionnel en moins d'un mois est réaliste — à condition de s'appuyer sur les rasters pré-calculés de l'IGN et de renoncer au machine learning supervisé. L'écosystème Python offre des implémentations prêtes à l'emploi pour chaque métrique terrain (pente, Sky View Factor, rugosité, accumulation de flux). Aucun outil existant — ni KelFoncier, ni Buildrz, ni UrbanSIMUL (Ecologie) — n'exploite le LiDAR HD pour scorer la constructibilité physique d'une parcelle, ce qui constitue un véritable avantage de premier entrant. La contrainte ZAN (Zéro Artificialisation Nette) amplifie la demande pour ce type d'outil de densification. Le risque principal n'est pas technique : il réside dans la définition d'une méthodologie de scoring crédible et dans le volume de données à télécharger.

Les données LiDAR HD de l'IGN sont massives, ouvertes et exploitables immédiatement

Le programme national LiDAR HD de l'IGN, lancé en 2021, (IGN) vise une couverture intégrale de la France métropolitaine et des DROM (hors Guyane) (IGN) (IGN) d'ici **fin 2026**. En mars 2025, **55 blocs de modèles numériques (~135 000 km²)** sont déjà diffusés, (IGN) et plus de **400 000 km²** de nuages de points classifiés sont disponibles. (IGN) La couverture inclut notamment la Corse (intégralement), (IGN) les Bouches-du-Rhône, (IGN) l'Alsace, (IGN) la Normandie partielle, les Alpes, les Pyrénées, et des villes comme Rennes, Rouen, Toulouse, Nancy et Chambéry. (IGN) Une carte interactive de suivi est accessible sur (macarte.ign.fr). (data.gouv.fr)

L'IGN fournit **trois produits raster dérivés essentiels**, tous au format GeoTIFF 32 bits à **résolution 50 cm**, (IGN) découpés en dalles de **1 km × 1 km** (data.gouv.fr) en Lambert 93 (EPSG:2154) :

- **MNT** (Modèle Numérique de Terrain) : altitude du sol nu (data.gouv.fr) (Cartes.gouv.fr)
- **MNS** (Modèle Numérique de Surface) : enveloppe supérieure incluant bâtiments et végétation (IGN)
- **MNH** (Modèle Numérique de Hauteur) : MNS − MNT, soit la hauteur des objets au-dessus du sol (Cartes.gouv.fr)

Les nuages de points classifiés sont distribués au format (SIG & Territoires) **LAZ 1.4 (COPC)** (IGN) avec une densité minimale de **10 impulsions/m²** (arXiv +2) et une classification en 11 classes (SIG & Territoires) (sol, bâtiment, végétation basse/moyenne/haute, eau, pont, sursol pérenne). (data.gouv.fr) Chaque dalle LAZ pèse **150 à 500 Mo** en compressé. Pour une commune moyenne de 15 km², il faut compter **15-20 dalles**, soit environ 2-8 Go en nuages de points, ou seulement **quelques centaines de Mo** en rasters MNT/MNS/MNH.

La licence est Etalab 2.0 (IGN) (IGN) — réutilisation commerciale libre, mondiale, illimitée. (IGN) Seule obligation : mentionner « IGN » comme source. Le téléchargement s'effectue via (cartes.gouv.fr/telechargement/) ou via l'API de la Géoplateforme ((data.geopf.fr/telechargement/)), qui expose un standard Atom avec trois méthodes (GetCapabilities, GetResource, Download) limitées à 10 requêtes/seconde. (Cartes.gouv.fr)

Décision architecturale critique : utiliser les rasters MNT/MNS/MNH pré-calculés par l'IGN plutôt que de traiter les nuages de points bruts. Cela élimine 60-70 % de la complexité technique et rend le projet faisable pour une petite équipe.

Le cadastre et les données de zonage sont entièrement accessibles en open data

Trois sources complémentaires couvrent les besoins du projet en données vectorielles :

Le Cadastre Etalab (`cadastre.data.gouv.fr/datasets/cadastre-etalab`) est la source recommandée pour les parcelles. Il fournit des fichiers GeoJSON et Shapefile par commune, incluant parcelles, sections, bâti et lieux-dits. Dernière mise à jour : PCI décembre 2025. La couverture est totale (toute la France depuis septembre 2025). Les parcelles Etalab sont en WGS84 — une reprojection en Lambert 93 est nécessaire avant croisement avec les rasters LiDAR.

L'API Carto de l'IGN (`apicarto.ign.fr`) offre un accès REST sans clé API aux parcelles cadastrales (source PCI Express), avec sortie en GeoJSON. Elle est limitée à **1 000 résultats par requête** mais permet une intégration programmatique directe. Le module Urbanisme (GPU) de cette même API donne accès aux zonages PLU, prescriptions et servitudes de chaque parcelle.

Le Géoportail de l'Urbanisme (`geoportail-urbanisme.gouv.fr`) centralise les PLU/PLUi de toutes les communes françaises. Les exports hebdomadaires sont disponibles en GeoPackage et Shapefile. C'est la source autoritaire pour déterminer si une parcelle est en zone U, AU, A ou N.

Le croisement parcelles × rasters est trivial avec **rasterstats** : `zonal_stats(parcelles, raster.tif, stats=['mean','max','std'])` calcule les statistiques zonales `pytz` (altitude moyenne, pente max, hauteur de végétation) pour chaque polygone parcellaire en quelques secondes. `Geobgu` `PyPI` La bibliothèque **rasterio.mask** permet de découper un raster par géométrie de parcelle. `Geoscripting-wur` Pour couvrir une commune entière à cheval sur plusieurs dalles, un Virtual Raster (VRT) via `gdalbuildvrt` évite de fusionner physiquement les fichiers.

Chaque métrique terrain a une implémentation Python prête à l'emploi

L'écosystème Python géospatial est mature. Voici l'état des lieux par métrique, avec les bibliothèques recommandées et les performances réelles :

Pente — La métrique la plus simple. GDAL (`gdaldem slope`) traite une dalle 2000×2000 pixels en **moins d'une seconde**. WhiteboxTools utilise un algorithme polynomial Florinsky (2016) plus robuste au bruit. `GitHub` RichDEM offre une API Python directe. `Readthedocs` Trois lignes de code suffisent.

Sky View Factor — La métrique la plus exigeante en calcul, mais **rvt-py** (Relief Visualization Toolbox, Université de Ljubljana) fournit une implémentation complète et testée. L'appel `rvt.vis.sky_view_factor(dem=arr, resolution=0.5, svf_n_dir=16, svf_r_max=10)` retourne un array numpy de valeurs SVF entre 0 et 1. `Readthedocs` Avec 16 directions et un rayon de 10 pixels (5 m), le temps de calcul est de **2-5 secondes par dalle** de 1 km². Avec un rayon de 50 pixels (25 m) et 32 directions — nécessaire pour capturer l'effet d'enclavement par les bâtiments voisins — compter **15-60 secondes par dalle**. La bibliothèque supporte le traitement tuilé pour les grandes zones. `Readthedocs` Des alternatives existent : svfpy, `GitHub` HORAYZON (ray-tracing haute performance), `GitHub` topocalc. `GitHub`

Rugosité / TRI (Terrain Ruggedness Index) — Disponible dans GDAL (`gdaldem TRI`), WhiteboxTools (multi-échelle), `Jblindsay` xDEM (`dem.terrain_ruggedness_index()`), `Readthedocs` ou implémentable en une ligne

avec `scipy.ndimage.generic_filter`. Temps : **< 1 seconde par dalle**.

Accumulation de flux — RichDEM (`rd.FlowAccumulation(dem, method='D8')`) après remplissage des dépressions. WhiteboxTools offre un pipeline hydrologique complet. Jblindsay Essentiel pour détecter les zones inondables. Temps : **2-5 secondes par dalle**.

Hauteur des bâtiments — Le MNH de l'IGN donne directement cette information. Cartes.gouv.fr Si non disponible : `ndsm = mns_array - mnt_array`. Une seule opération numpy.

Enclavement / accessibilité — OSMnx télécharge le réseau routier d'une commune en une ligne GitHub (`ox.graph_from_place('Commune, France')`). Le scoring d'accessibilité se calcule par distance euclidienne ou réseau entre le centroïde de chaque parcelle et la route la plus proche via `geopandas.sjoin_nearest()`.

Performances globales pour une commune de 20 km²

Opération	Temps estimé
Lecture de 20 dalles GeoTIFF	~5 s
Pente (GDAL)	~10 s
SVF (rvt-py, r=10, 16 dir)	~60 s
TRI (GDAL)	~10 s
Accumulation de flux (RichDEM)	~60 s
Zonal stats / 1000 parcelles	~5 s
Total pipeline	**~5-10 minutes**

Un laptop avec **16 Go de RAM** gère confortablement une commune de 20 km² : chaque dalle de 2000×2000 pixels en float32 occupe **16 Mo** en mémoire, soit ~320 Mo pour 20 dalles par bande. Avec 6 bandes simultanées : **~2 Go**, largement dans les limites.

Aucun concurrent n'exploite le LiDAR HD pour la constructibilité physique

L'analyse du paysage concurrentiel révèle un **angle mort systémique** : tous les acteurs existants évaluent la constructibilité sous l'angle réglementaire (conformité PLU), jamais sous l'angle physique du terrain.

KelFoncier, leader commercial avec les principaux promoteurs français (Nexity, Vinci, Kaufman & Broad), propose 50+ critères de recherche foncière et un diagnostic de constructibilité instantané — mais entièrement basé sur le PLU et le cadastre. **Aucune donnée LiDAR**. **Buildrz** (racheté par One Click LCA en 2024) génère des scénarios 3D conformes au PLU en 30 minutes grâce à l'IA générative One Click LCA — mais ses modèles 3D sont construits à partir de règles d'urbanisme, pas de la réalité terrain. **UrbanSIMUL** (Cerema/INRAE),

outil public gratuit (Ecologie) utilisé par 60 % des intercommunalités, détecte les dents creuses et parcelles vacantes (Revue Diagonal) — mais par analyse cadastrale, sans micro-topographie ni LiDAR.

NamR enrichit 34 millions de bâtiments existants avec 200+ attributs, (Open data france) mais cible le bâti existant, pas les terrains vierges. **UrbanPrint** (Efficacity/CSTB) évalue le bilan carbone de projets déjà conçus (Francevilledurable) (Efficacity) — un outil aval, pas amont.

Le consortium **Urba(IA)** (Buildrz + CentraleSupélec + Dassault Systèmes + NamR + IRT SystemX), lancé en 2024, explore l'IA pour l'urbanisme à Paris-Saclay (Urbanisme) — mais **n'utilise pas le LiDAR HD** pour le scoring terrain.

Terra-IA occupe donc un créneau réellement vacant : la **constructibilité physique** d'une parcelle, mesurée à partir de données terrain haute résolution. Les features exclusives possibles incluent l'analyse micro-topographique par parcelle (pente, rugosité), l'estimation de la densité végétale et du coût de défrichement, le risque de micro-drainage et d'accumulation d'eau, l'enclavement réel mesuré par SVF, et la distance d'accès au réseau viaire.

La loi **Climat & Résilience** (ZAN) impose de diviser par deux la consommation d'espaces naturels d'ici 2031 et d'atteindre zéro artificialisation nette d'ici 2050. (Rhone Government) Cette contrainte crée une demande massive pour des outils de densification urbaine — exactement le cas d'usage de Terra-IA.

Ce qui est réaliste en un mois — et ce qui ne l'est pas

Le MVP faisable en 4 semaines

Semaine 1 — Pipeline données : télécharger les dalles MNT + MNS + MNH pour la commune cible via l'API Géoplateforme ou le script (lidarhd_ign_downloader). Construire un VRT. Charger les parcelles Etalab. Valider l'alignement CRS.

Semaine 2 — Métriques terrain : implémenter le pipeline de calcul (pente via GDAL, SVF via rvt-py, TRI, accumulation de flux via RichDEM, hauteur bâtie via MNH, distance à la route via OSMnx). Calculer les statistiques zonales par parcelle avec rasterstats. (Geobgu) (GitHub)

Semaine 3 — Scoring et interface : concevoir une formule de scoring pondéré (pas de ML supervisé — un scoring déterministe par combinaison linéaire ou règles expertes). Construire l'app Streamlit avec streamlit-folium : carte choroplèthe des parcelles colorées par score, fiche détaillée par parcelle, filtres.

Semaine 4 — Tests et polish : tester sur 2-3 communes différentes, gérer les cas limites (parcelles à cheval sur dalles, données manquantes, petites parcelles), rédiger la documentation.

Les vrais bottlenecks

- **Téléchargement des données** : 2-8 Go par commune en nuages de points, quelques centaines de Mo en rasters. La limite API de 10 req/s peut ralentir le téléchargement en lot. (Cartes.gouv.fr) Prévoir 30-60 minutes pour une commune.

- **Couverture géographique** : vérifier impérativement sur la carte d'avancement que la commune cible est couverte. En mars 2025, ~135 000 km² sont disponibles en rasters IGN — loin de la totalité.
- **Méthodologie de scoring** : c'est le vrai défi intellectuel. Quels poids attribuer à la pente vs. le SVF vs. l'accumulation de flux ? Sans données labellisées (parcelles effectivement construites vs. refusées), un scoring supervisé est hors de portée en un mois. Un scoring déterministe par règles expertes est réaliste.
- **Complexité du SVF** : modérée mais non triviale. Avec rvt-py, l'implémentation est prête à l'emploi. Le paramétrage (rayon de recherche, nombre de directions) impacte fortement le résultat et le temps de calcul. Un rayon de 25 m (50 pixels) avec 16 directions est un bon compromis.

Ce qui est trop ambitieux pour ce délai

- **ML supervisé** : la labellisation de parcelles (constructible/non constructible) nécessite des données ground truth (permis de construire géolocalisés, avis d'experts) qui ne sont pas facilement disponibles. Un Random Forest sur features LiDAR est techniquement simple, mais constituer un jeu d'entraînement fiable prend des semaines.
- **Traitement des nuages de points bruts** : inutile si les rasters MNT/MNS/MNH sont disponibles. Traiter les LAZ avec PDAL est 10-100× plus lent et complexe. Medium
- **Couverture multi-communes automatisée** : le pipeline pour une commune est faisable ; le rendre générique et robuste pour n'importe quelle commune de France est un projet à part entière.
- **Intégration PLU automatique** : parser les règlements de PLU (COS, CES, hauteur max, recul) nécessite un traitement NLP ou une base de données structurée qui n'existe pas encore de manière fiable.
- **Interface de production** : une app Streamlit de démonstration est réaliste ; une application web déployée et performante en production ne l'est pas.

Stack technique recommandée

```
conda create -n terra-ia python=3.11
conda install -c conda-forge rasterio geopandas richdem whitebox gdal
pip install rvt-py rasterstats laspy[lazrs] osmnx streamlit streamlit-folium
```

Conclusion : un positionnement fort sur un angle mort du marché

Terra-IA a un **avantage de premier entrant réel**. Le LiDAR HD de l'IGN est le jeu de données 3D ouvert le plus riche jamais produit en France GitHub (10 pts/m², IGN classification en 11 classes, GitHub rasters 50 cm), IGN data.gouv.fr et aucun acteur commercial ne l'exploite pour le scoring de constructibilité. arXiv L'écosystème Python (rvt-py, WhiteboxTools, RichDEM, rasterstats) rend le calcul de chaque métrique terrain accessible en quelques lignes de code. Esri Community Le pipeline complet — du téléchargement IGN à l'affichage Streamlit — peut être fonctionnel en **3 semaines** pour une commune donnée.

La recommandation stratégique est de livrer un **scoring déterministe multi-critères** (pente, SVF, hauteur du sursol, rugosité, accumulation de flux, accessibilité route) plutôt qu'un modèle ML, de cibler une commune déjà couverte en rasters MNH/MNT/MNS, et de positionner la démonstration comme preuve de concept pour un outil de densification urbaine dans le contexte ZAN. L'ajout futur de ML supervisé (entraîné sur les permis de construire accordés/refusés) et de l'intégration PLU automatique constituerait la feuille de route post-MVP. Le fait qu'aucun outil — ni KelFoncier à 50 critères, Land Detector ni Buildrz avec son IA générative, Issuu ni UrbanSIMUL avec 1 500 collectivités utilisatrices Revue Diagonal — ne propose d'analyse terrain physique depuis le LiDAR HD est le signal le plus fort de l'opportunité.