TERRA-IA

Morphological Buildability Scoring using LiDAR HD

Rapport de Faisabilité & Note Technique — Capstone Project

Document de référence interne — Équipe projet
Version 1.0 — Mars 2026

Champ	Valeur
Projet	Terra-IA
Zone pilote	Chambéry, Savoie (73065)
Données principales	IGN LiDAR HD — MNT / MNH / MNS (50 cm)
Licence données	Etalab 2.0 — open data libre
Modèle ML	XGBoost + SHAP
Interface	Streamlit + Folium
Délai	4 semaines
Cadre	Capstone IA — pipeline ML complet

1. Contexte & Problématique

1.1 Le cadre réglementaire : la loi ZAN

La loi Climat & Résilience (2021) impose à la France un objectif de Zéro Artificialisation Nette (ZAN) : diviser par deux la consommation d'espaces naturels d'ici 2031, et atteindre zéro artificialisation nette d'ici 2050. Conséquence directe : il n'est plus possible de construire sur des terres naturelles. La densification intra-urbaine devient la seule voie de développement immobilier viable.

> *Le ZAN crée une demande massive pour des outils capables d'identifier et d'évaluer le potentiel de densification à l'intérieur des villes existantes.*

1.2 Le problème opérationnel

Identifier les parcelles urbaines sous-exploitées (dents creuses, friches, parkings, fonds de parcelles) est une tâche aujourd'hui effectuée manuellement, lentement et de façon non systématique. Or, la présence d'un terrain vide ne suffit pas à le rendre constructible : la faisabilité d'un projet immobilier dépend fortement de contraintes physiques du terrain.

Ces contraintes morphologiques incluent :

- La topographie locale : pente, micro-relief, rugosité
- L'enclavement : ouverture au ciel, hauteur des bâtiments environnants
- L'hydrologie : risque de drainage, accumulation d'eau
- L'accessibilité : distance et nature de la voirie adjacente

> *Ces analyses sont aujourd'hui manuelles, non scalables, coûteuses et non reproductibles. Aucun outil existant ne les automatise à partir de données LiDAR haute résolution.*

1.3 La distinction clé : constructibilité morphologique vs réglementaire

Terra-IA ne prédit pas la constructibilité légale, qui dépend du PLU (Plan Local d'Urbanisme), des servitudes, et des règlements de zone. Ces informations existent par ailleurs via le Géoportail de l'Urbanisme.

> *Terra-IA mesure la friction morphologique du terrain : les contraintes physiques qui influencent la faisabilité et le coût réel d'un projet de construction. C'est une couche d'analyse complémentaire, pas un remplacement des outils réglementaires.*

2. Description du Projet

2.1 Définition

Terra-IA est un moteur d'analyse géospatiale basé sur l'intelligence artificielle qui identifie et classe les parcelles urbaines selon leur potentiel de constructibilité morphologique.

En exploitant les données LiDAR HD haute résolution de l'IGN (50 cm), le système extrait des features terrain et urbaines par parcelle, puis produit un indice de potentiel constructible (CPI — Constructibility Potential Index) allant de 0 à 100. Le résultat est une carte interactive permettant à des professionnels de l'immobilier, des collectivités ou des bureaux d'études d'identifier rapidement les opportunités de densification.

2.2 Positionnement concurrentiel

L'analyse du marché révèle un angle mort systémique : tous les acteurs existants évaluent la constructibilité sous l'angle réglementaire, jamais sous l'angle physique du terrain.

- **KelFoncier** : 50+ critères cadastraux et PLU — aucune donnée LiDAR
- **Buildrz** : génération de scénarios 3D conformes PLU — modèles construits sur règles, pas sur terrain réel
- **UrbanSIMUL (Cerema/INRAE)** : détection dents creuses cadastrales — sans microtopographie
- **NamR** : enrichissement bâti existant — cible les bâtiments, pas les terrains vacants

> *Terra-IA est le premier outil à exploiter le LiDAR HD IGN pour scorer la constructibilité physique à l'échelle parcellaire. C'est un avantage de premier entrant réel.*

2.3 Utilisateurs cibles

- Promoteurs immobiliers — prospection foncière intra-urbaine
- Collectivités locales — planification de la densification ZAN
- Foncières et fonds d'investissement — analyse de portefeuille
- Bureaux d'études — pré-qualification de sites

2.4 Zone pilote : Chambéry (Savoie, 73)

Chambéry a été sélectionnée comme zone pilote pour trois raisons :

- **Couverture LiDAR HD disponible :** les rasters MNT, MNH et MNS sont accessibles en téléchargement immédiat via l'API Géoplateforme IGN (code commune : 73065)
- **Diversité morphologique exceptionnelle :** centre historique dense, tissu pavillonnaire périphérique, zones industrielles, relief alpin marqué — variance élevée sur toutes les features terrain

- **Taille optimale :** ~60 000 habitants, environ 15-20 dalles kilométriques, traitables en quelques minutes sur un laptop standard

> *La diversité morphologique de Chambéry est critique pour le ML : un territoire trop homogène produirait un dataset à faible variance, rendant l'apprentissage peu informatif.*

3. Sources de Données

3.1 IGN LiDAR HD — Source principale

Le programme national LiDAR HD de l'IGN, lancé en 2021, produit une cartographie 3D de la France entière à une résolution de 50 cm et une densité de 10 points/m². En mars 2026, plus de 135 000 km² de rasters sont disponibles en open data (licence Etalab 2.0 — réutilisation commerciale libre).

Produit	Description
MNT (50 cm)	Modèle Numérique de Terrain — altitude du sol nu, sans végétation ni bâtiments
MNH (50 cm)	Modèle Numérique de Hauteur — hauteur des objets au-dessus du sol (MNS − MNT)
MNS (50 cm)	Modèle Numérique de Surface — enveloppe supérieure incluant tout le sursol
Format	GeoTIFF 32 bits, dalles 1 km × 1 km, Lambert 93 (EPSG:2154)
Téléchargement	geoservices.ign.fr/lidarhd — API Géoplateforme (10 req/s)
Licence	Etalab 2.0 — open data, réutilisation libre y compris commerciale

> *Décision d'architecture clé : on exploite les rasters MNT/MNH/MNS pré-calculés par l'IGN plutôt que les nuages de points bruts (LAZ). Cela élimine 60-70% de la complexité technique sans perte d'information pour notre cas d'usage.*

3.2 Cadastre Etalab — Parcelles

Le Cadastre Etalab (cadastre.data.gouv.fr) fournit les géométries parcellaires de toute la France en GeoJSON et Shapefile, avec mise à jour mensuelle. Les parcelles sont en WGS84 — une reprojection en Lambert 93 est nécessaire avant croisement avec les rasters IGN.

3.3 OpenStreetMap — Réseau routier

OSMnx permet de télécharger le réseau routier d'une commune en une ligne de Python. Il est utilisé pour calculer la distance de chaque parcelle à la voirie la plus proche, indicateur d'accessibilité chantier.

3.4 Disponibilité et légalité

- Toutes les données sont en open data — aucune restriction d'usage
- Licence Etalab 2.0 pour le LiDAR HD — attribution IGN requise
- Cadastre Etalab — licence ouverte
- OpenStreetMap — ODbL

4. Pipeline Technique

4.1 Vue d'ensemble du pipeline

#	Étape	Description
01	**Data Ingestion**	Téléchargement rasters LiDAR HD IGN (MNT/MNH/MNS) + parcelles cadastrales Etalab + réseau OSM
02	**Raster Processing**	Alignement CRS → Lambert 93, fusion dalles (VRT), découpe par commune
03	**Feature Engineering**	Calcul slope, TRI, SVF (rvt-py), flow accumulation, hauteur voisinage, distance route
04	**Dataset Structuré**	Extraction zonal stats par parcelle → tableau 8 features × N parcelles
05	**CPI_baseline**	Score déterministe 0-100 par combinaison linéaire pondérée des features terrain
06	**XGBoost ML**	Entraînement sur labels proxy cadastraux, calibration des interactions non-linéaires
07	**SHAP Explicabilité**	Feature importance globale + locale → "pourquoi ce score ?"
08	**Streamlit Demo**	Carte interactive Folium + dashboard parcelle + filtres

4.2 Features terrain — Détail

Le cœur scientifique du projet réside dans l'extraction de 8 features géométriques 3D qui capturent les dimensions physiques déterminantes de la constructibilité morphologique.

Feature	Source	Description	Interprétation
`slope_mean_deg`	MNT	Pente moyenne en degrés	*Élevée = terrain difficile*
`slope_max_deg`	MNT	Pente maximale	*Détecte pentes locales critiques*
`tri_mean`	MNT	Terrain Ruggedness Index	*Régularité du sol*
`sky_view_factor`	MNH	Facteur de ciel visible (0-1)	*Enclavement / ouverture urbaine*
`height_obj_max`	MNH	Hauteur max des objets voisins	*Contexte bâti environnant*
`flow_accumulation`	MNT	Accumulation hydrologique	*Risque drainage / inondation*
`distance_to_road`	OSM	Distance à la voirie (m)	*Accessibilité chantier*
`surface_m2`	Cadastre	Surface de la parcelle (m²)	*Capacité d'accueil potentielle*

> *Choix délibéré : 8 features ciblées plutôt que 40. Un jury ML est plus impressionné par une analyse approfondie de 8 variables bien justifiées et expliquées par SHAP que par un vecteur de 40 features dont l'impact n'est pas maîtrisé.*

4.3 Stratégie de labellisation — Labels proxy

L'absence de labels directs ("cette parcelle est constructible/non constructible") est le principal défi ML du projet. La solution adoptée est la weak supervision par labels proxy cadastraux :

- **Positifs (constructible probable) :** parcelles où un bâtiment est apparu entre T1 et T2 selon la BD TOPO ou le MNH — construction effective confirmée
- **Négatifs (contrainte forte probable) :** parcelles vides depuis longtemps malgré un environnement bâti dense — non-construction persistante

> *Important : ces labels sont imparfaits par nature. L'objectif n'est pas de produire une vérité absolue, mais d'apprendre les interactions non-linéaires entre features et d'améliorer le ranking par rapport à la baseline déterministe. La robustesse aux labels bruités doit être documentée.*

4.4 Modélisation ML — CPI_baseline vs CPI_ML

Le projet adopte une stratégie en deux niveaux, standard dans l'industrie data :

- **CPI_baseline (déterministe) :** score 0-100 par combinaison linéaire pondérée des features. Rapide, transparent, reproductible. Sert de référence et de MVP démontrable immédiatement.
- **CPI_ML (XGBoost) :** modèle de gradient boosting entraîné sur les labels proxy. Capture les interactions non-linéaires entre features. Calibre les pondérations automatiquement. Justifie l'apport de l'IA.

> *La comparaison baseline vs ML est la démonstration clé de la valeur ajoutée de l'IA. Si le ML améliore le ranking de +15-20% sur la validation spatiale, l'argument est solide. Si l'amélioration est faible, c'est aussi un résultat scientifique honnête.*

4.5 Explicabilité — SHAP

SHAP (SHapley Additive exPlanations) est utilisé pour rendre le modèle interprétable à deux niveaux :

- **Global :** importance relative de chaque feature sur l'ensemble du dataset — "la pente explique 32% des variations de score"
- **Local :** contribution de chaque feature pour une parcelle spécifique — "ce score de 23/100 est bas principalement à cause de slope_max=18° et svf=0.31"

> *Sans explicabilité, le modèle reste une boîte noire. Avec SHAP, Terra-IA devient un outil de décision argumenté. C'est ce que les jurys IA attendent aujourd'hui.*

4.6 Validation spatiale

La validation utilise une approche de cross-validation spatiale plutôt qu'un split aléatoire classique :

- Entraînement sur les quartiers A, B, C de Chambéry
- Test sur le quartier D

Cette méthode prouve que le modèle capture des patterns morphologiques généraux, pas un surapprentissage local. C'est l'argument de robustesse le plus fort face à un jury expert.

5. Stack Technique

Librairie / Outil	Rôle dans Terra-IA
`rasterio`	Lecture/écriture rasters GeoTIFF LiDAR HD
`geopandas`	Manipulation geometries parcellaires (GeoJSON/Shapefile)
`rasterstats`	Extraction zonal stats (features) par parcelle
`rvt-py`	Calcul Sky View Factor sur rasters 50cm
`RichDEM`	Flow accumulation, terrain attributes hydrologiques
`scipy / numpy`	Calcul TRI, convolutions, opérations raster
`OSMnx`	Téléchargement réseau routier, calcul distances
`XGBoost`	Modèle ML principal (gradient boosting tabulaire)
`SHAP`	Explicabilité globale et locale du modèle
`Streamlit + Folium`	Interface web interactive + carte choroplèthe parcellaire

Installation

```
conda create -n terra-ia python=3.11
conda install -c conda-forge rasterio geopandas gdal
pip install rvt-py rasterstats richdem osmnx xgboost shap streamlit folium
```

6. Plan d'Action — 4 Semaines

Période	Phase	Actions	Livrable
Semaine 1	**Data Pipeline**	Télécharger rasters IGN (Chambéry 73065), parcelles cadastrales, réseau OSM. Aligner CRS. Tester pipeline raster → parcelle.	*Dataset initial par parcelle*
Semaine 2	**Feature Engineering**	Calculer : slope (GDAL), TRI (scipy), SVF (rvt-py), flow acc. (RichDEM), height (MNH), distance route (OSMnx). Zonal stats par parcelle.	*Dataset structuré 8 features × N parcelles*
Semaine 3	**Baseline + ML**	Construire CPI_baseline (score pondéré déterministe). Générer labels proxy (cadastre historique). Entraîner XGBoost. Comparer baseline vs ML.	*Modèle entraîné + métriques comparatives*
Semaine 4	**Explicabilité + Demo**	SHAP global + local. Validation spatiale (train quartier A / test quartier B). App Streamlit + carte Folium.	*Demo Terra-IA fonctionnelle*

6.1 Répartition des rôles recommandée

- **Profil tech ingénieur :** pipeline raster (semaine 1-2), modèle XGBoost + SHAP (semaine 3)
- **Profil semi-tech :** feature engineering (semaine 2), app Streamlit (semaine 4), validation
- **Profil business :** framing problème, storytelling soutenance, préparation démo, rapport technique

6.2 Première action concrète

Avant toute modélisation, la priorité immédiate est de valider le pipeline de données :

- Aller sur geoservices.ign.fr/lidarhd et télécharger 3-4 dalles MNT + MNH sur Chambéry
- Récupérer les parcelles cadastrales : cadastre.data.gouv.fr → commune 73065
- Lancer le script terra_ia_pipeline_test.py fourni par l'équipe technique
- Vérifier que le tableau de features par parcelle est généré correctement

> *Si le script produit un tableau avec des scores CPI_baseline en sortie sur les parcelles de Chambéry, le projet est techniquement validé et le reste est principalement du ML.*

7. Analyse de Faisabilité

7.1 Ce qui est faisable en 4 semaines

- Pipeline complet LiDAR → features → scoring pour Chambéry
- CPI_baseline déterministe fonctionnel
- Modèle XGBoost avec labels proxy cadastraux
- Explicabilité SHAP globale et locale
- App Streamlit avec carte Folium interactive

7.2 Ce qui est hors périmètre (décision volontaire)

- **Intégration PLU automatique :** parser les règlements PLU nécessite un traitement NLP complexe et une base structurée inexistante
- **Traitement nuages de points bruts (LAZ) :** inutile car les rasters IGN sont déjà calculés — coût sans gain
- **Couverture multi-communes automatisée :** la généralisation à n'importe quelle commune de France est un projet à part
- **Deep Learning 3D (PointNet, etc.) :** l'IGN a déjà fait la segmentation via Myria3D — refaire ce travail n'apporte pas de valeur

> *Note sur Myria3D (github.com/IGNF/myria3d) : c'est la librairie open source de l'IGN pour segmenter les nuages de points LiDAR. L'IGN l'a utilisée pour produire les rasters que nous exploitons. Terra-IA commence là où Myria3D s'arrête.*

7.3 Risques et mitigation

Risque	Mitigation
Couverture LiDAR incomplète sur Chambéry	Vérifiée — MNT/MNH/MNS disponibles (carte d'avancement IGN confirmée)
Labels proxy trop bruités	Documenter le bruit, tester robustesse, utiliser XGBoost (robuste aux outliers)
SVF lent à calculer	rvt-py : 15-60s/dalle avec rayon 25m, batch processing disponible
Dataset trop petit pour ML	Chambéry ~10 000 parcelles — suffisant pour XGBoost tabulaire
Jury questionne l'apport ML	Comparaison baseline vs ML chiffrée + SHAP = réponse préparée

7.4 Performances estimées

Pour une commune de 15-20 km² (~20 dalles) :

Opération	Temps estimé
Téléchargement dalles IGN	30-60 minutes (selon débit)
Calcul pente (GDAL)	~10 secondes

Calcul SVF (rvt-py)	~60 secondes
Calcul TRI + flow acc.	~70 secondes
Zonal stats / 1000 parcelles	~5 secondes
Pipeline complet	5-10 minutes
Scoring (inférence)	< 1 seconde

RAM requise : ~2 Go (6 bandes × 20 dalles × 16 Mo/bande). Compatible avec un laptop standard 16 Go.

8. Alignement avec les Critères Capstone

8.1 Grille d'évaluation

Critère Capstone	Comment Terra-IA y répond
Pipeline ML complet	8 étapes : ingestion → features → baseline → ML → SHAP → démo
Données non-triviales	LiDAR HD IGN (rasters 50cm) + cadastre + OSM — aucun toy dataset
Justification de l'IA	Comparaison CPI_baseline vs CPI_ML chiffrée + SHAP explicabilité
Analyse d'erreur	Quelles typologies de parcelles le modèle gère mal et pourquoi
Robustesse	Validation spatiale train/test sur quartiers différents
Code propre	Scripts Python modulaires src/ + README impeccable + requirements.txt
Démo fonctionnelle	Streamlit + Folium — aucune vidéo pré-enregistrée
Rapport technique	Ce document + blog article ou rapport détaillé

8.2 La question piège et la réponse préparée

> *Question jury : "Pourquoi de l'IA ici ? Une règle simple ne suffit-elle pas ?"*

> *Réponse : Nous montrons précisément cela. Notre CPI_baseline est la règle simple. Notre CPI_ML (XGBoost) apprend les interactions non-linéaires entre features — par exemple que l'effet de la pente dépend de l'enclavement, ce qu'une somme pondérée ne peut pas capturer. La comparaison chiffrée + SHAP prouve l'apport différentiel de l'IA.*

8.3 Phrase clé pour la soutenance

> *"Our objective is not to predict legal constructibility but to quantify morphological development constraints using high-resolution LiDAR data. We compare a deterministic baseline with a machine learning model to demonstrate the added value of AI in spatial analysis."*

9. Décisions Prises & Justifications

9.1 Décisions architecturales

- **Rasters IGN plutôt que nuages de points bruts :** élimine 60-70% de complexité, même information pour notre cas d'usage
- **XGBoost plutôt que deep learning 3D :** le problème est décisionnel (données tabulaires), pas perceptuel (vision 3D). XGBoost est plus performant sur tabulaire, explicable, rapide
- **8 features ciblées plutôt que 40 :** qualité de l'analyse > quantité. Chaque feature a une justification physique documentée
- **Streamlit plutôt qu'app React :** délai < 1 mois, démo live requise le jour J, équipe semi-technique. Streamlit = MVP fonctionnel en 2 jours
- **Chambéry plutôt que Paris :** taille gérable, couverture confirmée, diversité morphologique optimale pour le ML

9.2 Décisions scientifiques

- **Weak supervision plutôt que labels experts :** pas de dataset labellisé disponible en open data. Labels proxy cadastraux = solution pragmatique défendable
- **Validation spatiale plutôt que split aléatoire :** les données géospatiales ont une autocorrélation spatiale — le split aléatoire sur-estime les performances
- **Baseline déterministe comme référence :** nécessaire pour prouver l'apport du ML. C'est aussi le MVP livrable immédiatement

10. Prochaines Étapes Immédiates

> *Pour le checkpoint dans 2 jours : présenter le document de cadrage (project name, description, action plan, technical framework). Aucun code requis.*

> *Après le checkpoint : lancer le script terra_ia_pipeline_test.py sur 3-4 dalles Chambéry pour valider le pipeline. Si un tableau de features par parcelle sort, le projet est vert.*

Actions par ordre de priorité

- **[IMMÉDIAT]** Vérifier la couverture LiDAR Chambéry sur geoservices.ign.fr/lidarhd — FAIT (confirmé visuellement)
- **[J+0]** Télécharger 3-4 dalles MNT + MNH Chambéry (coordonnées Lambert 93 ~915000, 6510000)
- **[J+0]** Récupérer parcelles cadastre.data.gouv.fr → commune 73065 → GeoJSON
- **[J+1]** Lancer terra_ia_pipeline_test.py — vérifier tableau features en sortie
- **[J+2]** Checkpoint : présenter le document de cadrage
- **[Semaine 2]** Feature engineering complet sur Chambéry entière
- **[Semaine 3]** Baseline + XGBoost + première comparaison
- **[Semaine 4]** SHAP + validation spatiale + Streamlit

Ressources clés

- **Données LiDAR :** geoservices.ign.fr/lidarhd
- **Cadastre :** cadastre.data.gouv.fr → commune 73065
- **Carte avancement IGN :** macarte.ign.fr/carte/mThSup/diffusionMNxLiDARHD
- **Documentation technique IGN :** cartes.gouv.fr/aide/fr/partenaires/ign/observations-regulieres-territoire/relief/
- **Script pipeline :** terra_ia_pipeline_test.py (fourni, ~200 lignes, Python 3.11)